1. Saúde da Mulher na África Subsaariana

Contracepção, pré-natal, assistência materno-infantil e desigualdades sociais: Quanto das diferenças rurais e urbanas se relacionam à riqueza e à escolaridade?

2. Equipe

Henrique Lima Gusmão (2025014508); Felipe Pires Franco (2025051411); Izabella Galdino Correia (2025096601); Alice Lina Oliveira da Silva (2025106933).

3. Descrição dos dados

--> Todos os scripts, dados e a aplicação para ver os dados traduzidos com o Python/Flask estão disponíveis no GitHub.

3.1 Obtenção dos dados brutos

1. Acessamos o DHS Program, solicitamos acesso e baixamos os dados em arquivos ZIP;
2. Extraímos os arquivos Stata (.dta) e selecionamos as entrevistas femininas, histórico de nascimentos, domicílios, moradores, crianças menores de 5 anos e entrevistas masculinas/parceiros.
3. Executamos os scripts de preparação e filtragem assistidos por IA, selecionamos as variáveis relevantes e convertemos os arquivos em CSV compactado (.csv.gz) para popular o banco SQLite e o banco relacional normalizado em 3FN.
4. Utilizamos a aplicação **Python/Flask** para traduzir e relacionar os códigos das variáveis e respostas aos seus significados em português e conferir se aqueles dados faziam sentido.

Abaixo descrevo como que automatizei a quantificação dos dados:

Seleção das pesquisas e cobertura temporal

Para cada país, escolhe-se o arquivo IR de maior fase disponível entre os arquivos locais, ordenando a parte numérica e o sufixo da fase. O recorte inclui os 37 países do manifesto do projeto.

O ano da entrevista na base normalizada entregue é entre 1989~2025.

Código

```
import subprocess
import sys
from pathlib import Path
from contextlib import closing
import sqlite3

for pacote in ("pandas", "matplotlib"):
    try:
        __import__(pacote)
    except ImportError:
        subprocess.check_call([sys.executable, "-m", "pip", "install", "-q", pacote])

import pandas as pd
from IPython.display import display

DDL = """
```

```
CREATE TABLE Pais(codigo TEXT PRIMARY KEY, nome TEXT NOT NULL UNIQUE);
CREATE TABLE Levantamento(id TEXT PRIMARY KEY, pais_codigo TEXT NOT NULL REFERENCES Pais(codigo), fase TEXT NOT NULL,
UNIQUE(pais_codigo,fase));
CREATE TABLE Domicilio(
  id TEXT PRIMARY KEY, levantamento_id TEXT NOT NULL REFERENCES Levantamento(id),
  cluster INTEGER NOT NULL, numero INTEGER NOT NULL, regiao INTEGER,
  residencia INTEGER CHECK(residencia IN(1,2)), riqueza INTEGER CHECK(riqueza BETWEEN 1 AND 5),
  eletricidade INTEGER CHECK(eletricidade IN(0,1)), fonte_agua INTEGER, membros INTEGER,
  origem TEXT NOT NULL CHECK(origem IN('HR','IR_sem_HR','IR_completo','MR_sem_HR')),
  UNIQUE(levantamento_id,cluster,numero));
CREATE TABLE Mulher(
  id TEXT PRIMARY KEY, domicilio_id TEXT NOT NULL REFERENCES Domicilio(id), linha INTEGER NOT NULL,
  idade INTEGER, escolaridade INTEGER CHECK(escolaridade BETWEEN 0 AND 3),
  filhos_nascidos_vivos INTEGER, idade_primeiro_nascimento INTEGER,
  UNIQUE(domicilio_id,linha));
CREATE TABLE Parceiro(
  id TEXT PRIMARY KEY, domicilio_id TEXT NOT NULL REFERENCES Domicilio(id), linha INTEGER NOT NULL,
  idade INTEGER, escolaridade INTEGER CHECK(escolaridade BETWEEN 0 AND 3),
  total_filhos INTEGER, idade_primeiro_filho INTEGER,
  UNIQUE(domicilio_id,linha));
CREATE TABLE Entrevista(
  mulher_id TEXT PRIMARY KEY REFERENCES Mulher(id), ano INTEGER, mes INTEGER,
  data_cmc INTEGER, peso REAL CHECK(peso>0), usa_metodo INTEGER CHECK(usa_metodo IN(0,1)),
  coorte TEXT NOT NULL CHECK(coorte IN('nucleo_e_contracepcao','nucleo_exclusivo','contracepcao')));
CREATE TABLE Nascimento(
  id TEXT PRIMARY KEY, mulher_id TEXT NOT NULL REFERENCES Mulher(id), indice INTEGER NOT NULL CHECK(indice>=1),
  ano INTEGER, mes INTEGER, data_cmc INTEGER, sexo INTEGER CHECK(sexo IN(1,2)), vivo INTEGER CHECK(vivo IN(0,1)),
  consultas_prenatal_codigo INTEGER, local_parto_codigo INTEGER, cesarea_codigo INTEGER,
  assistencia_medico_codigo INTEGER, assistencia_m3b_codigo INTEGER,
  origem TEXT NOT NULL CHECK(origem IN('BR','KR_sem_BR')), UNIQUE(mulher_id,indice));
CREATE TABLE Crianca(
  nascimento_id TEXT PRIMARY KEY REFERENCES Nascimento(id), idade_anos INTEGER,
  diarreia_codigo INTEGER, cartao_vacina_codigo INTEGER);
CREATE TABLE Vacina_Remedio(
  id INTEGER PRIMARY KEY, codigo TEXT NOT NULL UNIQUE, nome TEXT NOT NULL UNIQUE);
CREATE TABLE Crianca_Vacina(
  nascimento_id TEXT NOT NULL REFERENCES Crianca(nascimento_id),
  vacina_id INTEGER NOT NULL REFERENCES Vacina_Remedio(id),
  status_codigo INTEGER NOT NULL CHECK(status_codigo BETWEEN 0 AND 9),
  PRIMARY KEY(nascimento_id,vacina_id)) WITHOUT ROWID;
CREATE TABLE Morador(
  id TEXT PRIMARY KEY, domicilio_id TEXT NOT NULL REFERENCES Domicilio(id), linha INTEGER NOT NULL,
  sexo INTEGER, idade INTEGER, escolaridade_codigo INTEGER, relacao_chefe_codigo INTEGER,
  UNIQUE(domicilio_id,linha));
CREATE TABLE Metodo(
  id INTEGER PRIMARY KEY, nome TEXT NOT NULL UNIQUE, classe TEXT NOT NULL CHECK(classe IN('Moderno','Tradicional')));
CREATE TABLE Conhecimento_Metodo(
  mulher_id TEXT NOT NULL REFERENCES Mulher(id), metodo_id INTEGER NOT NULL REFERENCES Metodo(id),
  nivel INTEGER NOT NULL CHECK(nivel BETWEEN 0 AND 7), PRIMARY KEY(mulher_id,metodo_id)) WITHOUT ROWID;
"""
with closing(sqlite3.connect(":memory:")) as esquema:
    esquema.execute("PRAGMA foreign_keys=ON")
    esquema.executescript(DDL)
print("DDL executado - 13 relações com Chave Primária, Estrangeira, única e CHECK.")
```

```
DDL executado - 13 relações com Chave Primária, Estrangeira, única e CHECK.
```

Código

```
import csv
import gzip
import sqlite3
from contextlib import closing
from pathlib import Path
from uuid import uuid4
import pandas as pd
from database_python.carregar_sqlite import manifest_rows, columns_for, PREFIX_COLUMNS
from database_python.relatorio_notebook import construir_banco

COLUNAS = {
    "IR": ["v001", "v002", "v003", "v024", "v025", "v190", "v012", "v106", "v201", "v212",
```

```
            "v006", "v007", "v008", "v005", "v312"] + [f"v304_{i:02d}" for i in range(1, 10)],
    "HR": ["hv001", "hv002", "hv024", "hv025", "hv270", "hv206", "hv201", "hv009"],
    "PR": ["hv001", "hv002", "hvidx", "hv104", "hv105", "hv106", "hv101"],
    "BR": ["v001", "v002", "v003", "bidx", "b1", "b2", "b3", "b4", "b5", "m14", "m15", "m17", "m3a", "m3b"],
    "KR": ["v001", "v002", "v003", "bidx", "b1", "b2", "b3", "b4", "b5", "m14", "m15", "m17", "b8", "h11", "h1",
           "h2", "h3", "h4", "h5", "h6", "h7", "h8", "h9"],
    "MR": ["mv001", "mv002", "mv003", "mv024", "mv025", "mv190", "mv012", "mv106", "mv201", "mv212"],
}
TABELAS_RECODE = dict(IR="Mulher", HR="Domicilio", PR="Morador", BR="Nascimento", KR="Crianca", MR="Parceiro")


def ler_csvs(dados, origem):
    """Lê CSVs gzip em lotes, alinhando as colunas de cada país pelo manifesto."""
    arquivo_esquemas = dados / "manifesto_selecao.csv"
    if not arquivo_esquemas.exists():
        arquivo_esquemas = dados.parent.parent / "docs/esquemas_csv.csv"
    manifesto = [m for m in manifest_rows(arquivo_esquemas) if m["recode"] in COLUNAS]
    origem.executescript("CREATE TABLE Pais(pais_codigo TEXT PRIMARY KEY, nome_pais TEXT); "
                         "CREATE TABLE Levantamento(levantamento_id TEXT PRIMARY KEY, pais_codigo TEXT, fase TEXT);")
    paises = {m["pais_codigo"]: m["pais_nome"] for m in manifesto}
    pesquisas = {(m["pais_codigo"], m["fase"]) for m in manifesto}
    origem.executemany("INSERT INTO Pais VALUES (?, ?)", paises.items())
    origem.executemany("INSERT INTO Levantamento VALUES (?, ?, ?)",
                       [(f"{pais}_{fase}", pais, fase) for pais, fase in sorted(pesquisas)])
    for recode, selecionadas in COLUNAS.items():
        itens = [m for m in manifesto if m["recode"] == recode]
        if not itens:
            raise ValueError(f"Recode obrigatório ausente no manifesto: {recode}")
        tabela = TABELAS_RECODE[recode]
        colunas = PREFIX_COLUMNS + selecionadas
        tipos = [f'"{c}" TEXT' for c in PREFIX_COLUMNS] + [f'"{c}" NUMERIC' for c in selecionadas]
        origem.execute(f"CREATE TABLE {tabela} ({', '.join(tipos)})")
        inserir = f"INSERT INTO {tabela} VALUES ({', '.join('?' for _ in colunas)})"
        with gzip.open(dados / f"{recode}.csv.gz", "rt", encoding="utf-8-sig", newline="") as arquivo:
            leitor = csv.reader(arquivo)
            if next(leitor, None) != columns_for(itens[0]):
                raise ValueError(f"Cabeçalho incompatível: {recode}")
            for item in itens:
                esquema = columns_for(item)
                posicoes = [esquema.index(c) if c in esquema else None for c in colunas]
                esperado = [item["pais_codigo"], item["pais_nome"],
                            f"{item['pais_codigo']}_{item['fase']}", item["fase"], item["arquivo_origem"]]
                lote = []
                for _ in range(int(item["linhas"])):
                    linha = next(leitor, None)
                    if linha is None or len(linha) != len(esquema) or linha[:5] != esperado:
                        raise ValueError(f"Linha incompatível com o manifesto: {recode}/{item['pais_codigo']}")
                    lote.append([linha[i] or None if i is not None else None for i in posicoes])
                    if len(lote) == 10000:
                        origem.executemany(inserir, lote)
                        lote.clear()
                origem.executemany(inserir, lote)
            if next(leitor, None) is not None:
                raise ValueError(f"Linhas excedentes: {recode}")
    origem.commit()


def verificar_banco(destino):
    """Retorna o resumo de um banco válido e populado; banco ausente/vazio exige carga."""
    if not destino.exists():
        return None
    with closing(sqlite3.connect(":memory:")) as esperado:
        esperado.executescript(DDL)
        definicoes = dict(esperado.execute("SELECT name, sql FROM sqlite_master WHERE type='table'"))
    with closing(sqlite3.connect(str(destino))) as banco:
        atual = dict(banco.execute("SELECT name, sql FROM sqlite_master WHERE type='table'"))
        if not definicoes.keys() <= atual.keys():
            return None
        if any(''.join(sql.split()).lower() != ''.join(atual[t].split()).lower() for t, sql in definicoes.items()):
            raise ValueError("Esquema existente incompatível com o DDL normalizado.")
        falhas = banco.execute("PRAGMA foreign_key_check").fetchall()
        if falhas:
            raise ValueError(f"Integridade referencial inválida: {falhas[:5]}")
        contagens = {t: banco.execute(f"SELECT COUNT(*) FROM {t}").fetchone()[0] for t in definicoes}
```

```
        obrigatorias = ["Pais", "Levantamento", "Domicilio", "Mulher", "Parceiro", "Entrevista",
                        "Nascimento", "Crianca", "Vacina_Remedio", "Crianca_Vacina", "Morador",
                        "Metodo", "Conhecimento_Metodo"]
        if any(contagens[t] == 0 for t in obrigatorias):
            return None
        return pd.DataFrame(contagens.items(), columns=["Tabela", "Registros"])


def preparar_banco(dados, destino, suplementos=()):
    """Reutiliza o banco válido ou carrega CSVs e publica o banco após a validação."""
    dados, destino = Path(dados).resolve(), Path(destino).resolve()
    if destino.name == "saude_mulher_dhs.db":
        raise ValueError("O banco de preparação não pode ser substituído pela carga normalizada.")
    resumo = verificar_banco(destino)
    if resumo is not None:
        resumo.attrs["acao"] = "reutilizado"
        return resumo
    temporario = destino.with_name(f".carga_dhs_{uuid4().hex}.db")
    try:
        with closing(sqlite3.connect(str(temporario))) as origem:
            ler_csvs(dados, origem)
        construir_banco(temporario, destino, suplementos, ddl=DDL)
    finally:
        temporario.unlink(missing_ok=True)
    resumo = verificar_banco(destino)
    if resumo is None:
        raise ValueError("Carga concluída sem os registros essenciais.")
    resumo.attrs["acao"] = "criado"
    return resumo
```

Código

```
from pathlib import Path
from IPython.display import display

raiz = Path.cwd()
resumo_banco = preparar_banco(raiz / "dados/relevantes", raiz / "saude_mulher_normalizado.db")
print(f"Banco {resumo_banco.attrs['acao']}; integridade referencial validada nas 13 tabelas.")
display(resumo_banco)
```

	Tabela	Registros
0	Pais	37
1	Levantamento	114
2	Domicilio	567348
3	Mulher	584004
4	Parceiro	236070
5	Entrevista	584004
6	Nascimento	930745
7	Crianca	282641
8	Vacina_Remedio	8
9	Crianca_Vacina	1174167
10	Morador	1884683
11	Metodo	9
12	Conhecimento_Metodo	4437906

```
Banco reutilizado; integridade referencial validada nas 13 tabelas.
```

Coloco a entidade, o valor bruto e a base normalizada com as pesquisas complementares fora do escopo principal:

- Mulheres/entrevistas, 407.600, 584.004
- Domicílios, 385.457, 567.348
- Nascimentos, 877.412. 930.745

O núcleo abrange 37 países, 1.884.683 moradores, 282.641 crianças menores de 5 anos e 236.070 parceiros/homens entrevistados. A ampliação acrescenta 176.404 entrevistas suplementares.

Código

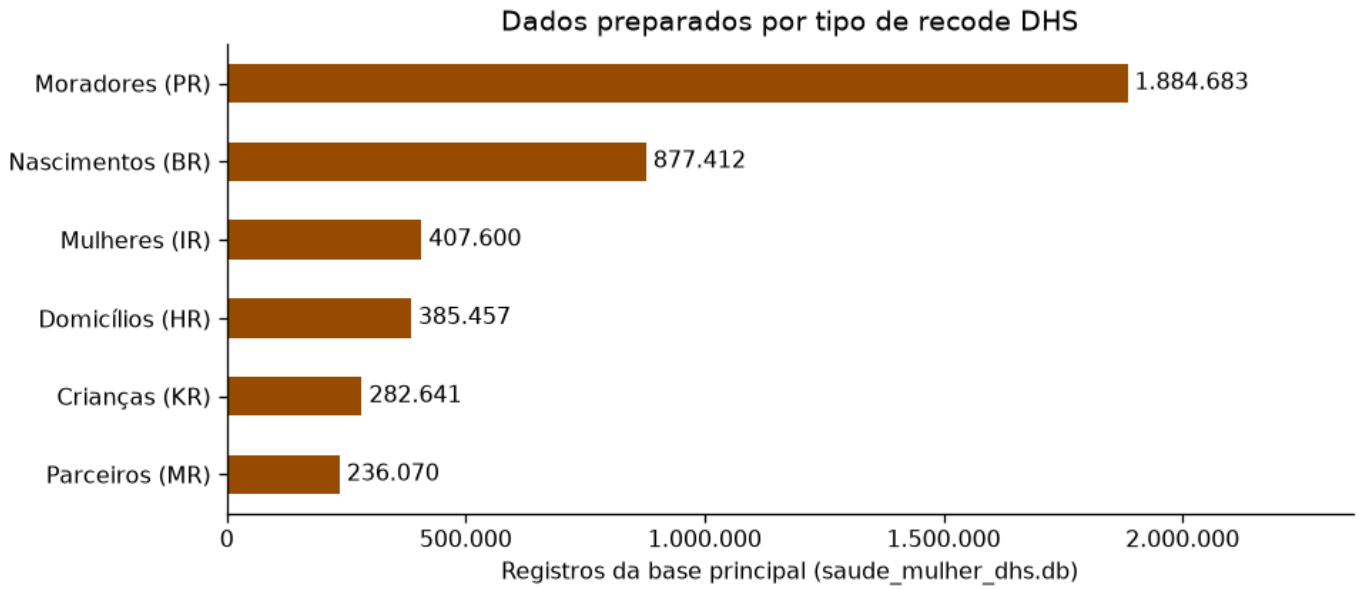
```
from pathlib import Path
from contextlib import closing
import sqlite3
import pandas as pd
import matplotlib.pyplot as plt
from matplotlib.ticker import FuncFormatter
from IPython.display import display

raiz = Path.cwd()
plt.rcParams.update({"font.size": 10, "axes.spines.top": False,
                     "axes.spines.right": False, "figure.dpi": 115})
azul = "#964B00"

def exibir(fig):
    fig.tight_layout()
    display(fig)
    plt.close(fig)

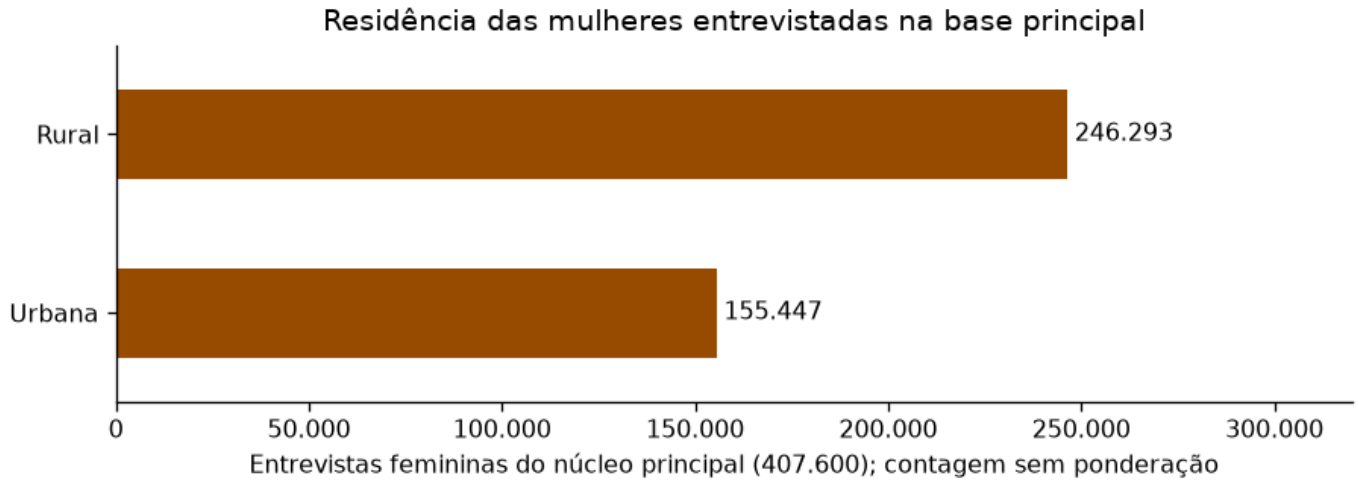
with closing(sqlite3.connect(str(raiz / "saude_mulher_dhs.db"))) as banco:
    tipos = {
        "Mulher": "Mulheres (IR)",
        "Nascimento": "Nascimentos (BR)",
        "Domicilio": "Domicílios (HR)",
        "Morador": "Moradores (PR)",
        "Crianca": "Crianças (KR)",
        "Parceiro": "Parceiros (MR)",
    }
    registros = pd.Series({nome: banco.execute(f"SELECT COUNT(*) FROM {tabela}").fetchone()[0]
                           for tabela, nome in tipos.items()})
    residencia = pd.read_sql_query("""
        SELECT v025 AS residencia, COUNT(*) AS entrevistas
        FROM Mulher GROUP BY v025
    """, banco)

fig, ax = plt.subplots(figsize=(8.5, 3.8))
registros.sort_values().plot.barh(ax=ax, color=azul)
ax.set(xlabel="Registros da base principal (saude_mulher_dhs.db)", title="Dados preparados por tipo de recode DHS",
       xlim=(0, registros.max() * 1.25))
for y, valor in enumerate(registros.sort_values()):
    ax.text(valor, y, " " + f"{valor:,}".replace(",", "."), va="center")
ax.xaxis.set_major_formatter(FuncFormatter(lambda x, _: f"{x:,.0f}".replace(",", ".")))
exibir(fig)
```



Código

```
contagens = residencia.set_index("residencia").entrevistas.reindex([1, 2], fill_value=0)
contagens.index = ["Urbana", "Rural"]
sem_informacao = int(residencia.entrevistas.sum() - contagens.sum())
fig, ax = plt.subplots(figsize=(8, 3))
contagens.plot.barh(ax=ax, color=azul)
ax.set(xlabel="Entrevistas femininas do núcleo principal (407.600); contagem sem ponderação",
       title="Residência das mulheres entrevistadas na base principal", xlim=(0, contagens.max() * 1.3))
for y, valor in enumerate(contagens):
    ax.text(valor, y, " " + f"{valor:,}".replace(",", "."), va="center")
ax.xaxis.set_major_formatter(FuncFormatter(lambda x, _: f"{x:,.0f}".replace(",", ".")))
exibir(fig)
print(f"Residência sem informação válida no núcleo principal (Sudão): {sem_informacao:,} entrevistas.".replace(",",
"."))
```



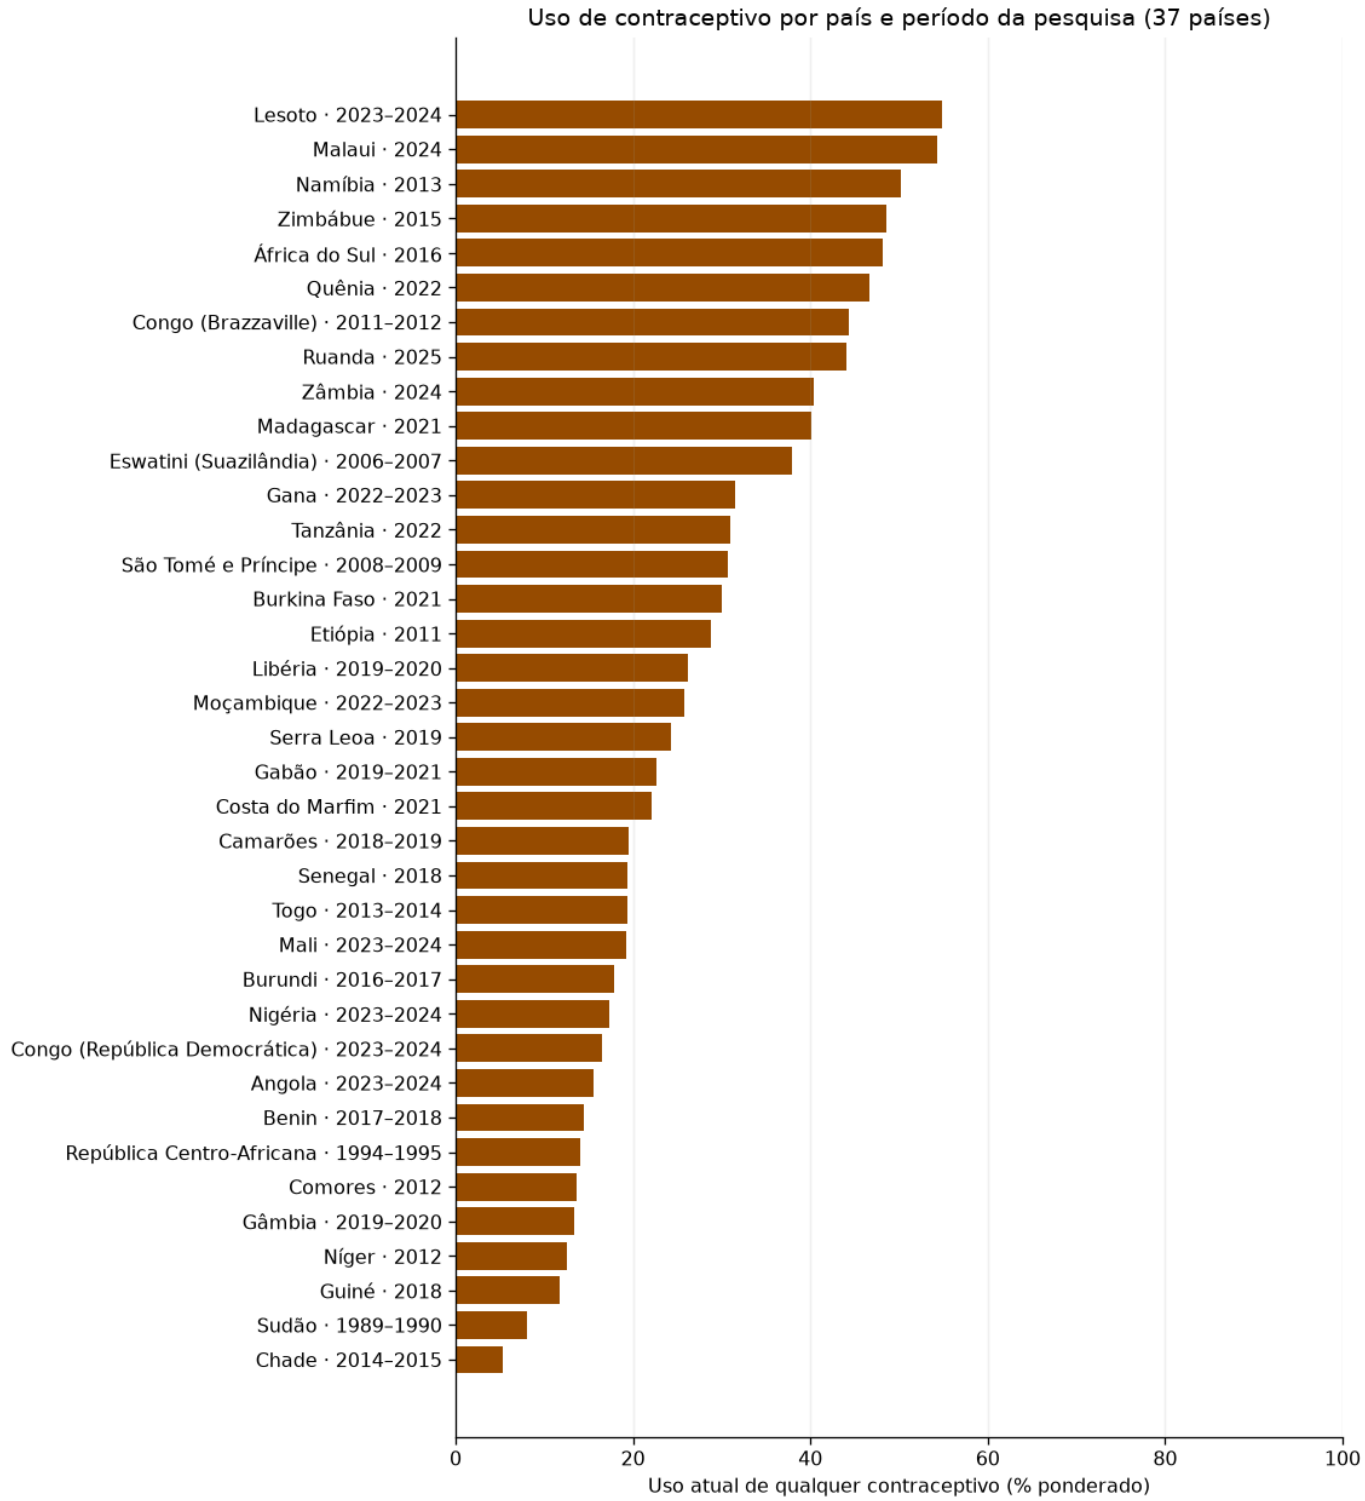

```
Residência sem informação válida no núcleo principal (Sudão): 5.860 entrevistas.
```

Código

```
with closing(sqlite3.connect(str(raiz / "saude_mulher_normalizado.db"))) as banco:
    contracepcao = pd.read_sql_query("""
        SELECT p.codigo, p.nome, MIN(e.ano) AS inicio, MAX(e.ano) AS fim,
               ROUND(100.0 * SUM(e.peso * e.usa_metodo) / SUM(e.peso), 2) AS uso_percentual
        FROM Entrevista e
        JOIN Mulher m ON m.id = e.mulher_id
```

```
        JOIN Domicilio d ON d.id = m.domicilio_id
        JOIN Levantamento l ON l.id = d.levantamento_id
        JOIN Pais p ON p.codigo = l.pais_codigo
        WHERE e.coorte != 'nucleo_exclusivo' AND e.usa_metodo IS NOT NULL AND e.peso > 0
        GROUP BY p.codigo, p.nome
    """, banco).sort_values("uso_percentual")

periodos = contracepcao.apply(lambda r: str(int(r.inicio)) if r.inicio == r.fim
                              else f"{int(r.inicio)}–{int(r.fim)}", axis=1)
rotulos = contracepcao.nome + " · " + periodos
fig, ax = plt.subplots(figsize=(10, 11))
ax.barh(rotulos, contracepcao.uso_percentual, color=azul)
ax.set(xlim=(0, 100), xlabel="Uso atual de qualquer contraceptivo (% ponderado)",
       title="Uso de contraceptivo por país e período da pesquisa (37 países)")
ax.grid(axis="x", alpha=.15)
exibir(fig)
```



Código

```
from pathlib import Path
from time import perf_counter
from statistics import median
import sqlite3
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from IPython.display import display, Markdown, HTML
from database_python.relatorio_notebook import (
    abrir_banco, sha256, consultar, detalhes, mostrar, barras, mapa, pares,
    AZUL, LARANJA,
)
```

```
conn, origem, hash_origem = abrir_banco(Path.cwd())
nomes = dict(conn.execute("SELECT codigo, nome FROM Pais"))

def consulta(sql, amostra=False):
    return consultar(conn, sql, amostra)

def nomear(df):
    return df.rename(index=nomes).sort_index()

cobertura = consulta("""
SELECT p.codigo, p.nome, l.fase, e.coorte, MIN(e.ano) AS ano_min, MAX(e.ano) AS ano_max,
       COUNT(*) AS mulheres,
       SUM(e.usa_metodo IS NOT NULL) AS resposta_contraceptiva,
       SUM(d.riqueza IS NOT NULL) AS riqueza_disponivel,
       SUM(d.origem='HR') AS mulheres_com_HR
FROM Entrevista e
JOIN Mulher m ON m.id = e.mulher_id
JOIN Domicilio d ON d.id = m.domicilio_id
JOIN Levantamento l ON l.id = d.levantamento_id
JOIN Pais p ON p.codigo = l.pais_codigo
GROUP BY p.codigo, p.nome, l.fase, e.coorte
ORDER BY p.nome
""")
assert cobertura.codigo.nunique() == 37
assert len(cobertura) == 47

panorama = consulta("""
SELECT p.codigo, p.nome, l.fase, MIN(e.ano) AS ano_min, MAX(e.ano) AS ano_max,
       COUNT(*) AS entrevistas, SUM(e.usa_metodo IS NOT NULL AND e.peso > 0) AS respostas_validas,
       ROUND(100.0 * SUM(CASE WHEN e.usa_metodo IS NOT NULL AND e.peso > 0 THEN e.peso * e.usa_metodo END) /
       NULLIF(SUM(CASE WHEN e.usa_metodo IS NOT NULL AND e.peso > 0 THEN e.peso END), 0), 2) AS uso_percentual
FROM Entrevista e
JOIN Mulher m ON m.id = e.mulher_id
JOIN Domicilio d ON d.id = m.domicilio_id
JOIN Levantamento l ON l.id = d.levantamento_id
JOIN Pais p ON p.codigo = l.pais_codigo
WHERE e.coorte != 'nucleo_exclusivo'
GROUP BY p.codigo, p.nome, l.fase
ORDER BY p.nome
""")
assert len(panorama) == 37 and panorama.uso_percentual.notna().all()
print(f"Cobertura validada: {cobertura.mulheres.sum():,} entrevistas totais em 47 coortes
({cobertura.codigo.nunique()} países); recorte temático de contracepção com {panorama.entrevistas.sum():,}
entrevistas.".replace(",", "."))
```

▼ Resultado completo · 47 linhas

codigo	nome	fase	coorte	ano_min	ano_max	mulheres	resposta_contraceptiva	riqueza_disponivel	mulheres_com_HR
AO	Angola	81	nucleo_e_contracepcao	2023	2024	14717	14717	14717	14717
BJ	Benin	71	nucleo_e_contracepcao	2017	2018	15928	15928	15928	15928
BF	Burkina Faso	81	nucleo_e_contracepcao	2021	2021	17659	17659	17659	17659
BU	Burundi	71	nucleo_e_contracepcao	2016	2017	17269	17269	17269	17269
CM	Camarões	71	contracepcao	2018	2019	14677	13527	14677	0
CM	Camarões	82	nucleo_exclusivo	2022	2022	6532	0	6532	6532
TD	Chade	71	nucleo_e_contracepcao	2014	2015	17719	17719	17719	17719
KM	Comores	61	nucleo_e_contracepcao	2012	2012	5329	5329	5329	5329
CG	Congo (Brazzaville)	61	nucleo_e_contracepcao	2011	2012	10819	10819	10819	10819

codigo	nome	fase	coorte	ano_min	ano_max	mulheres	resposta_contraceptiva	riqueza_disponivel	mulheres_com_HR
CD	Congo (República Democrática)	81	nucleo_e_contracepcao	2023	2024	27583	27583	27583	27583
CI	Costa do Marfim	81	nucleo_e_contracepcao	2021	2021	14877	14877	14877	14877
SZ	Eswatini (Suazilândia)	51	nucleo_e_contracepcao	2006	2007	4987	4987	4987	4987
ET	Etiópia	81	nucleo_e_contracepcao	2011	2011	8885	8885	8885	8885
GA	Gabão	71	nucleo_e_contracepcao	2019	2021	11043	9507	11043	11043
GH	Gana	82	nucleo_exclusivo	2019	2019	5181	0	5181	5181
GH	Gana	8C	contracepcao	2022	2023	15014	15014	15014	0
GN	Guiné	71	contracepcao	2018	2018	10874	10874	10874	0
GN	Guiné	82	nucleo_exclusivo	2021	2021	5912	0	5912	5912
GM	Gâmbia	81	nucleo_e_contracepcao	2019	2020	11865	11865	11865	11865
LS	Lesoto	81	nucleo_e_contracepcao	2023	2024	6413	6413	6413	6413
LB	Libéria	7A	contracepcao	2019	2020	8065	8065	8065	0
LB	Libéria	81	nucleo_exclusivo	2022	2022	4513	0	4513	4513
MD	Madagascar	81	nucleo_e_contracepcao	2021	2021	18869	18869	18869	18869
MW	Malaui	81	nucleo_e_contracepcao	2024	2024	21587	21587	20849	21587
ML	Mali	83	nucleo_exclusivo	2021	2021	10765	0	10765	10765
ML	Mali	8A	contracepcao	2023	2024	20354	17202	20354	0
MZ	Moçambique	82	nucleo_e_contracepcao	2022	2023	13183	13183	13183	13183
NM	Namíbia	61	nucleo_e_contracepcao	2013	2013	10018	9176	10018	10018
NG	Nigéria	81	nucleo_exclusivo	2021	2021	14476	0	14476	14476
NG	Nigéria	8B	contracepcao	2023	2024	39050	39050	39050	0
NI	Níger	61	contracepcao	2012	2012	11160	11160	11160	0
NI	Níger	82	nucleo_exclusivo	2021	2021	5795	0	5795	5795
KE	Quênia	81	nucleo_exclusivo	2020	2020	6771	0	6771	6771
KE	Quênia	8C	contracepcao	2022	2022	32156	32156	32156	0
CF	República Centro-Africana	31	nucleo_e_contracepcao	1994	1995	5884	5884	0	5884
RW	Ruanda	91	nucleo_e_contracepcao	2025	2025	14283	14283	14283	14283
SN	Senegal	81	nucleo_e_contracepcao	2018	2018	9414	9414	9414	9414
SL	Serra Leoa	73	nucleo_exclusivo	2016	2016	8501	0	8501	8501
SL	Serra Leoa	7A	contracepcao	2019	2019	15574	15574	15574	0
SD	Sudão	02	nucleo_e_contracepcao	1989	1990	5860	5860	0	0
ST	São Tomé e Príncipe	51	nucleo_e_contracepcao	2008	2009	2615	2615	2615	2615

codigo	nome	fase	coorte	ano_min	ano_max	mulheres	resposta_contraceptiva	riqueza_disponivel	mulheres_com_HR
TZ	Tanzânia	82	nucleo_e_contracepcao	2022	2022	15254	15254	15254	15254
TG	Togo	61	contracepcao	2013	2014	9480	9480	9480	0
TG	Togo	71	nucleo_exclusivo	2017	2017	4674	0	4674	4674
ZW	Zimbábue	72	nucleo_e_contracepcao	2015	2015	9955	9955	9955	9955
ZM	Zâmbia	81	nucleo_e_contracepcao	2024	2024	13951	13951	13951	13951
ZA	África do Sul	71	nucleo_e_contracepcao	2016	2016	8514	8514	8514	8514

▼ Resultado completo · 37 linhas

codigo	nome	fase	ano_min	ano_max	entrevistas	respostas_validas	uso_percentual
AO	Angola	81	2023	2024	14717	14717	15.58
BJ	Benin	71	2017	2018	15928	15928	14.41
BF	Burkina Faso	81	2021	2021	17659	17659	30.06
BU	Burundi	71	2016	2017	17269	17269	17.89
CM	Camarões	71	2018	2019	14677	13527	19.52
TD	Chade	71	2014	2015	17719	17719	5.35
KM	Comores	61	2012	2012	5329	5329	13.66
CG	Congo (Brazzaville)	61	2011	2012	10819	10819	44.34
CD	Congo (República Democrática)	81	2023	2024	27583	27583	16.55
CI	Costa do Marfim	81	2021	2021	14877	14877	22.05
SZ	Eswatini (Suazilândia)	51	2006	2007	4987	4987	37.88
ET	Etiópia	81	2011	2011	8885	8885	28.76
GA	Gabão	71	2019	2021	11043	9507	22.68
GH	Gana	8C	2022	2023	15014	15014	31.47
GN	Guiné	71	2018	2018	10874	10874	11.76
GM	Gâmbia	81	2019	2020	11865	11865	13.42
LS	Lesoto	81	2023	2024	6413	6413	54.91
LB	Libéria	7A	2019	2020	8065	8065	26.25
MD	Madagascar	81	2021	2021	18869	18869	40.07
MW	Malaui	81	2024	2024	21587	20849	54.35
ML	Mali	8A	2023	2024	20354	17202	19.24
MZ	Moçambique	82	2022	2023	13183	13183	25.82
NM	Namíbia	61	2013	2013	10018	9176	50.17
NG	Nigéria	8B	2023	2024	39050	39050	17.35
NI	Níger	61	2012	2012	11160	11160	12.50
KE	Quênia	8C	2022	2022	32156	32156	46.61
CF	República Centro-Africana	31	1994	1995	5884	5884	14.08
RW	Ruanda	91	2025	2025	14283	14283	44.13
SN	Senegal	81	2018	2018	9414	9414	19.42
SL	Serra Leoa	7A	2019	2019	15574	15574	24.27
SD	Sudão	02	1989	1990	5860	5860	7.99
ST	São Tomé e Príncipe	51	2008	2009	2615	2615	30.73

codigo	nome	fase	ano_min	ano_max	entrevistas	respostas_validas	uso_percentual
TZ	Tanzânia	82	2022	2022	15254	15254	30.93
TG	Togo	61	2013	2014	9480	9480	19.33
ZW	Zimbábue	72	2015	2015	9955	9955	48.55
ZM	Zâmbia	81	2024	2024	13951	13951	40.34
ZA	África do Sul	71	2016	2016	8514	8514	48.15

```
Cobertura validada: 584.004 entrevistas totais em 47 coortes (37 países); recorte temático de contracepção com 510.884
entrevistas.
```

3.2 Dados processados e Reprodutibilidade

Pesquisamos a saúde da mulher na África Subsaariana, com foco em contracepção, pré-natal, assistência ao parto, vacinação infantil, contexto intradomiciliar e diferenças de residência, riqueza e escolaridade. A base principal contém 407.600 entrevistas femininas de 37 nações.

No modelo relacional revisado da seção 5, Nascimento representa o evento do parto e Crianca armazena cada filho individualmente. Partos múltiplos podem compartilhar nascimento_id, mantendo sexo, sobrevivência e índice da origem separados por criança. Essa organização é uma proposta de modelagem; os dados e as contagens atuais ainda refletem a implementação anterior, em que cada nascimento corresponde a um filho.

Arquivos brutos que podem ser consultados no GitHub:

- IR.csv.gz (Mulher, Entrevista, Conhecimento_Metodo), com Idade, escolaridade, parturição, entrevista, pesos amostrais e conhecimento/uso de métodos contraceptivos
- BR.csv.gz (Nascimento), com Histórico de nascimentos, consultas de pré-natal, local do parto, cesárea e assistência médica/enfermagem
- HR.csv.gz (Domicilio), com Moradia (urbana/rural), quintil de riqueza, eletricidade, fonte de água e total de membros
- PR.csv.gz (Morador), com Composição familiar, sexo, idade, escolaridade e relação com o chefe do domicílio
- KR.csv.gz (Crianca, Crianca_Vacina), com Crianças menores de 5 anos, diarreia recente, cartão de vacina e histórico das 8 vacinas
- MR.csv.gz (Parceiro), com Homens/parceiros entrevistados no domicílio: idade, escolaridade, total de filhos e idade ao primeiro filho

Para reconstruir a versão ampliada, são necessários os CSVs zipados, o esquema, os scripts e os dez arquivos Stata do manifesto de contracepção (todos já no GitHub). Use o script abaixo para executar a reconstrução.

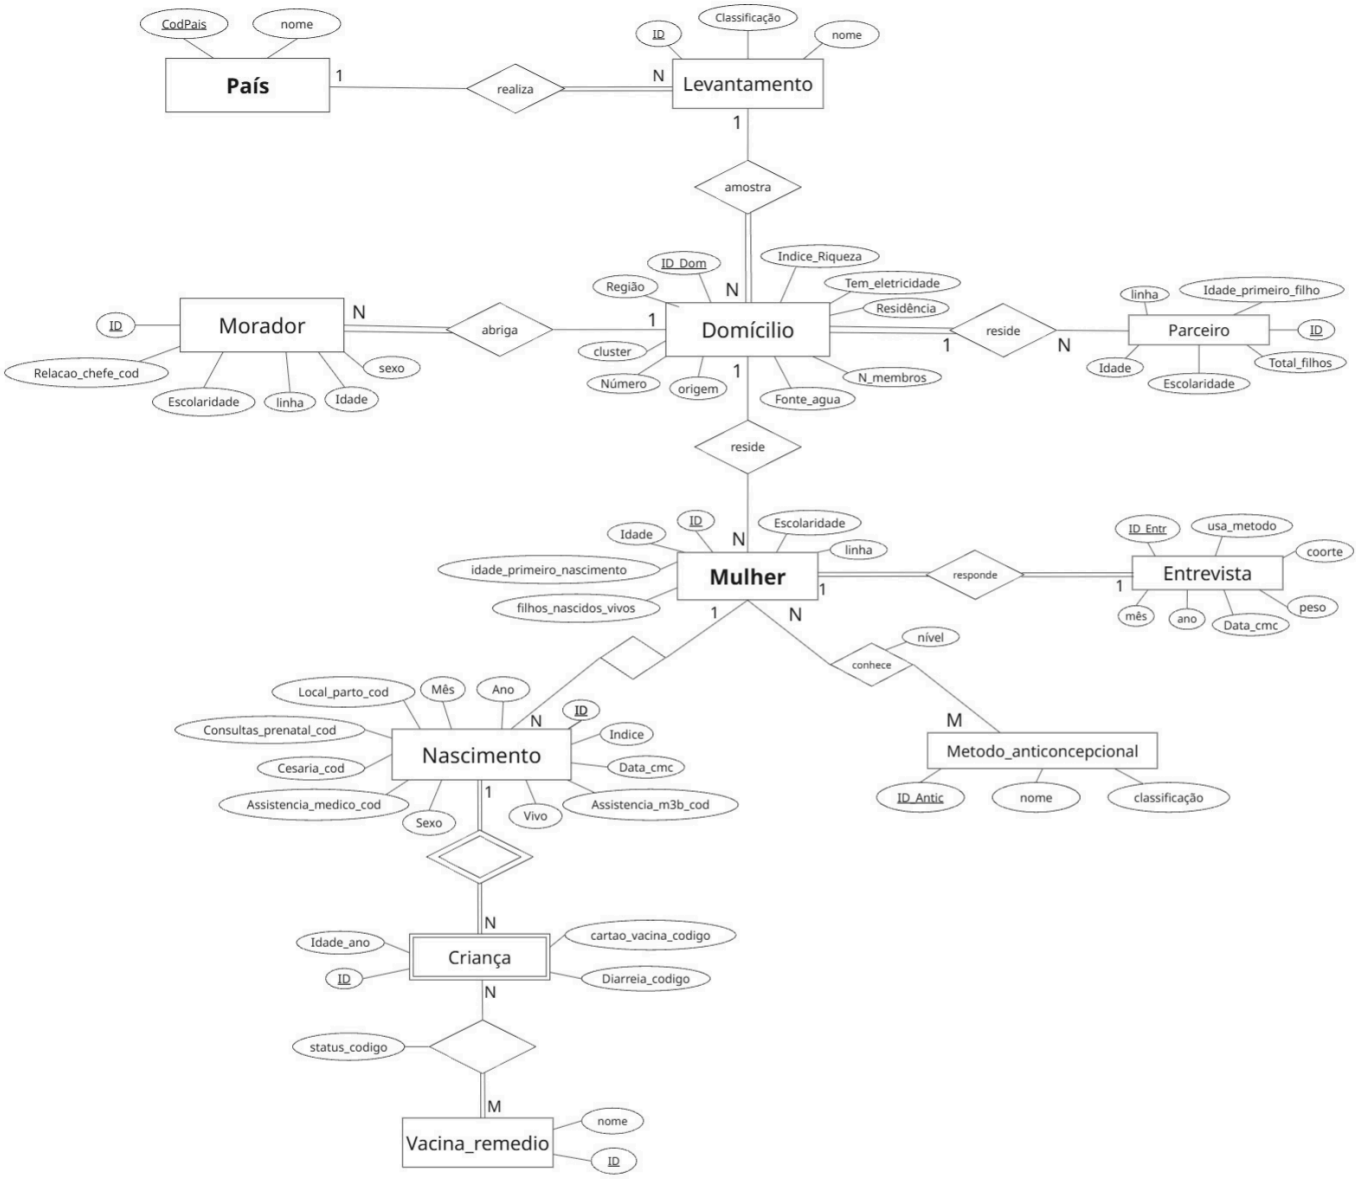
```
import json
from pathlib import Path

raiz = Path.cwd()
manifesto = json.loads(
    (raiz / "docs/manifesto_contracepcao.json").read_text(encoding="utf-8")
)
# Extraia previamente os dez arquivos nesta pasta, preservando seus nomes.
pasta = raiz / "dados/completo/extraidos"
suplementos = []
for item in manifesto:
    candidatos = [p for p in pasta.rglob("*")
                  if p.is_file() and p.name.casefold() == item["arquivo_origem"].casefold()]
    if len(candidatos) != 1:
        raise FileNotFoundError(f"Esperado um arquivo para {item['arquivo_origem']}")
    suplementos.append(dict(item, caminho_origem=str(candidatos[0])))

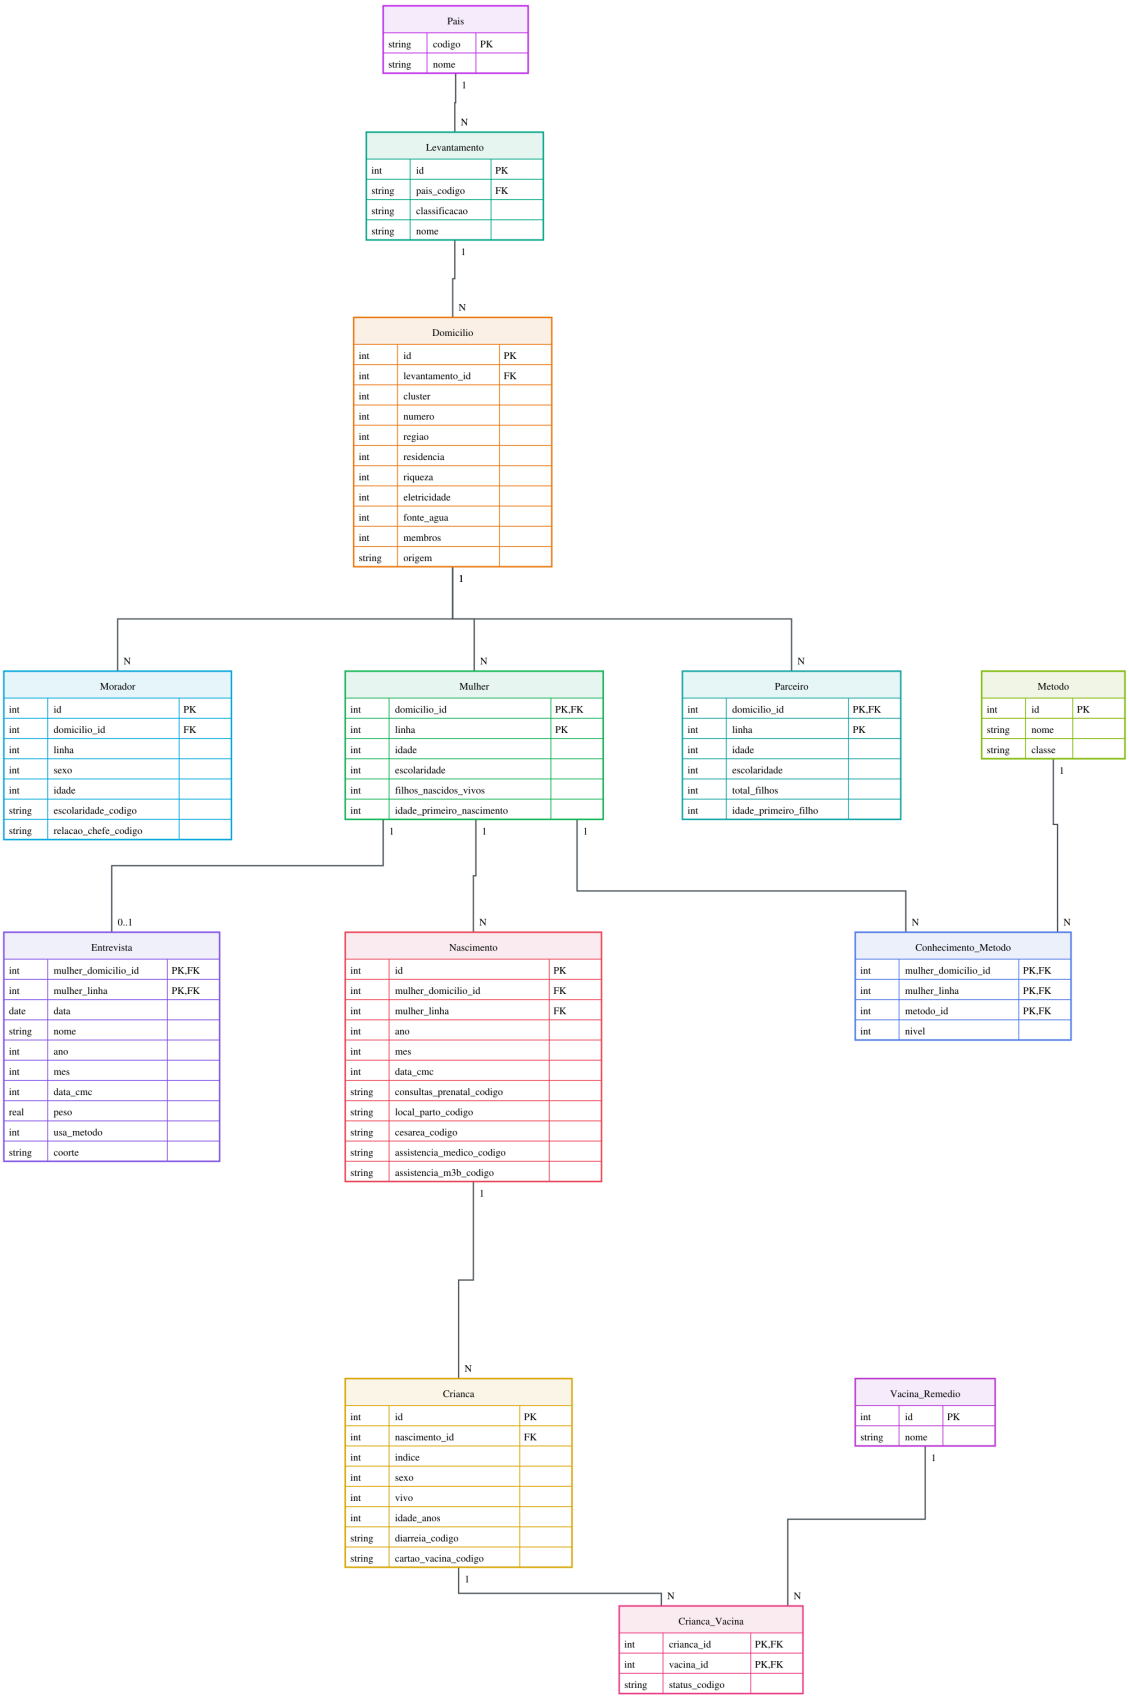
destino = raiz / "saude_mulher_reconstruido.db"
if destino.exists():
```

```
    raise FileExistsError("Escolha um destino novo para verificar a reconstrução.")
resumo = preparar_banco(raiz / "dados/relevantes", destino, suplementos=suplementos)
display(resumo)
```

4. Diagrama ER



5. Diagrama relacional



Pais(codigo, nome) PK: codigo

Levantamento(id, pais_codigo*, classificacao, nome) PK: id; FK: pais_codigo → Pais(codigo)

Domicilio(id, levantamento_id*, cluster, numero, regiao, residencia, riqueza, eletricidade, fonte_agua, membros, origem) PK: id; FK: levantamento_id → Levantamento(id)

Morador(id, domicilio_id*, linha, sexo, idade, escolaridade_codigo, relacao_chefe_codigo) PK: id; FK: domicilio_id → Domicilio(id)

Mulher(domicilio_id*, linha, idade, escolaridade, filhos_nascidos_vivos, idade_primeiro_nascimento) PK: (domicilio_id, linha); FK: domicilio_id → Domicilio(id)

Parceiro(domicilio_id*, linha, idade, escolaridade, total_filhos, idade_primeiro_filho) PK: (domicilio_id, linha); FK: domicilio_id → Domicilio(id)

Metodo(id, nome, classe) PK: id

Entrevista(mulher_domicilio_id*, mulher_linha*, data, nome, ano, mes, data_cmc, peso, usa_metodo, coorte) PK: (mulher_domicilio_id, mulher_linha); FK: (mulher_domicilio_id, mulher_linha) → Mulher(domicilio_id, linha)

Nascimento(id, mulher_domicilio_id*, mulher_linha*, ano, mes, data_cmc, consultas_prenatal_codigo, local_parto_codigo, cesarea_codigo, assistencia_medico_codigo, assistencia_m3b_codigo) PK: id; FK: (mulher_domicilio_id, mulher_linha) → Mulher(domicilio_id, linha)

Conhecimento_Metodo(mulher_domicilio_id*, mulher_linha*, metodo_id*, nivel) PK: (mulher_domicilio_id, mulher_linha, metodo_id); FK: (mulher_domicilio_id, mulher_linha) → Mulher(domicilio_id, linha); metodo_id → Metodo(id)

Crianca(id, nascimento_id*, indice, sexo, vivo, idade_anos, diarreia_codigo, cartao_vacina_codigo) PK: id; FK: nascimento_id → Nascimento(id)

Vacina_Remedio(id, nome) PK: id

Crianca_Vacina(crianca_id*, vacina_id*, status_codigo) PK: (crianca_id, vacina_id); FK: crianca_id → Crianca(id); vacina_id → Vacina_Remedio(id)

Partos múltiplos e atributos individuais

Neste modelo revisado, Nascimento representa o evento do parto de uma mulher. O relacionamento Nascimento–Crianca é 1:N: cada criança pertence a exatamente um parto, e um parto pode estar associado a várias crianças, inclusive gêmeos ou outros múltiplos.

Cada criança possui id próprio e referencia o mesmo nascimento_id quando compartilha o parto com seus irmãos. nascimento_id não é único em Crianca. sexo e vivo são atributos individuais de Crianca: irmãos do mesmo parto podem ter sexos e situações de sobrevivência diferentes. O campo indice identifica o registro individual do filho na origem DHS; ele não identifica o parto e, isoladamente, não é uma chave global.

Exemplo: Crianca(id=101, nascimento_id=50, sexo=1) e Crianca(id=102, nascimento_id=50, sexo=2) representam duas crianças de sexos diferentes vinculadas ao mesmo parto. Os dados do evento, como data, consultas de pré-natal, local e assistência ao parto, permanecem em Nascimento; os registros de vacinação continuam associados ao id de cada criança.

Correspondência com os dados: o banco e a carga existentes ainda representam Nascimento por filho, com sexo e vivo nessa tabela. A revisão acima é do modelo proposto. Aplicá-la ao banco exige uma migração que identifique os partos múltiplos com informações apropriadas da origem; não se deve agrupar registros apenas por mãe e mês/ano. As contagens apresentadas na descrição e nas saídas do notebook continuam sendo as do banco existente, não uma contagem de eventos de parto após essa migração.

6. Consultas

7. Autoavaliação dos membros

- **Henrique Lima Gusmão** - Sugestão de datasets; Solicitação de dados à agência americana; Plano de proposta da saúde da mulher africana; Importação dos 9GB de dados; Filtragem e normalização dos dados referentes às mulheres, domicílios, moradores, crianças e parceiros; Criação de repositório; Criação do Python/Flask para análise visual dos dados; Tradução dos códigos para os respectivos nomes das entidades; Seções Descrição e Inovação Social da primeira proposta; Descrição, Manipulação de dados, Consultas SQL, Otimização e Diagrama Relacional alinhado ao Diagrama ER.
- **Felipe Pires Franco** - Criação das Entidades na primeira entrega.
- **Izabella Galdino Correia** - Criação de Relacionamentos na primeira entrega; Modelo ER.
- **Alice Lina Oliveira da Silva** - Revisão técnica de ambas entregas e resolução dos problemas.

8. Declaração de Uso de Inteligência Artificial

Nesta seção, declaramos como ferramentas de Inteligência Artificial (IA) foram utilizadas durante o desenvolvimento deste trabalho.

Ferramentas e finalidades de uso

- **ChatGPT Sol 6.1 Alto, no Codex**: Para a criação do visualizador Python/Flask e automação da correlação dos códigos dos atributos ao inglês e tradução ao português; Correção pontual de erros nos códigos SQL.
- **Gemini 3.8 Flash no Antigravity**: Para a instalação de pacotes necessários para testar o notebook, verificação de alinhamento das tabelas do banco SQLite ao Diagrama ER.

O que não foi feito com IA

Análise crítica/qualitativa do significado destes dados, primeiras versões dos códigos SQL e escolha dos territórios, evitando assim possíveis vieses analíticos. Os autores assumem inteira responsabilidade por este conteúdo, considerando que todos os códigos foram testados, conferidos e modificados a critério da pesquisa quando necessário.